




A context aware attention network for hyperspectral content based image retrieval

BIL 495
İlk Sunum

Ahmed Semih Özmekik

Proje Danışmanı: Prof. Dr. Erchan Aptoula
Ekim 2020





Şekil 1: [1]

- Hiperspektral görüntüleme, insan gözünün 3 bantta algılayabildiği görünür ışıktan başka tayfı birçok banda ayırdığından, materyallerin tespitini ve ayrımını mümkün kılan yoğun spektral bilgiye sahiptir [2, 3].

• Proje Nedir?

- Hiperspektral görüntüler uzayında, bir görüntü ile arama yaparak koleksiyondan sorgu görüntüye en çok benzeyen görüntünün alımını gerçekleştiren program yapmaktır.

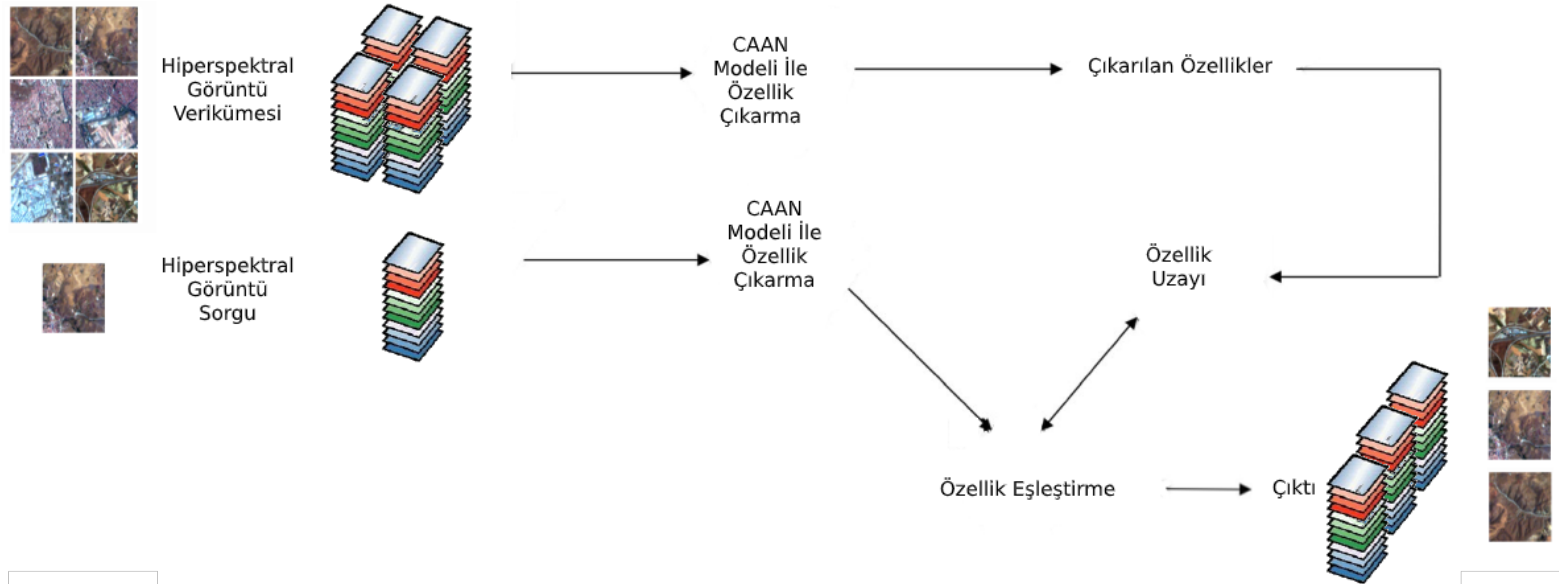
- İçerik Tabanlı Görüntü Alımı (CBIR), bilgisayarla görü tekniklerinin görüntü alma problemine (büyük veri tabanlarında dijital görüntülerin aranması problemine) uygulanmasıdır. “İçerik Tabanlı” arama; sorgunun anahtar sözcük ve etiket gibi meta verilerden ziyade görselin içeriğinin analiz edilerek yapıldığı anlamına gelir [4].

- CBIR’ın uygulanabilirlik alanları kapsamlıdır: Afet hassasiyeti, çevre analizi ve güvenlik için birçok jeobilim aracı talep edilmektedir [5].

- Bu projede geliştirilecek olan içerik tabanlı görüntü alma modeli derin öğrenme yöntemi kullanılmaktadır.

- Proje’de kullanılacak veri kümesi EO-1 Hyperion sensörü tarafından, Ankara çevresinde 2015 yılında elde edilen hiperspektral görüntülerdir.

Proje Tasarım Planı




- Hiperspektral görüntülerde içerik tabanlı görüntü almaya yönelik geliştirilen mevcut yaklaşımlar, “Endmember-based distance” [5, 6], “Bag of endmembers image descriptors” [7], “Spectral Unmixing” [8] gibi uzaklık metriği öğrenme yöntemleri olup, bu görüntülerin bant çokluğu iyi değerlendirilememektedir.
- Özgün yaklaşımımızda, derin öğrenme yöntemleriyle hyperspektral açıyı değerlendirmek üzere, Bağlama Duyarlı Dikkat Ağı (CAAN) kullanarak başarılı bir öznelik çıkarma modülü oluşturmayı hedefliyoruz.
- Veri kümesinde 216 hyperspektral görüntü ve her bir görüntüde 119 spektral kanal bulunmaktadır. Her bir görüntü, birden çok arazi örtüsü sınıfı ve bir arazi kullanım sınıfı ile etiketlenmiştir. Örneğin;
Arazi örtüsü sınıflarından bazıları: Çim Kaplı Toprak, Çıplak Toprak, Sarı Çatı...
Arazi kullanım sınıfları: Kırsal Alan, Kentsel Alan, Ekili Arazi, Orman.

- CAAN (Context Aware Attention Network) modeli oluşturulmalıdır.
- Model, hiperspektral görüntüler içeren bir veri kümesi üzerinde eğitilmelidir.
- Hiperspektral görüntülerden, spektral bantların çokluğu değerlendirilerek öznitelik çıkarımı yapılmalıdır: Eğitilmiş bir CAAN modelini öznitelik çıkarımında kullanmak için, modelden bir öznitelik vektörü oluşturma algoritması, mevcut şemalar [9] değerlendirilerek belirlenmelidir.
- Oluşturulan model ile veri kümesindeki hiperspektral görüntülerle bir öznitelik vektör veritabanı oluşturulmalıdır.
- Öznitelik eşleştirme için veritabanında vektör uzaklık hesaplaması yapılarak bir görüntü alımı yapılmalıdır.
- Model, test için ayrılmış verilerle veri kümesi üzerinde test edilmelidir.



Proje Gereksinimleri - 2

- Projemizde kullanılacak olan olan derin sinir ağı modelini geliştirmek için, CAAN modelini kullanan ve hiperspektral görüntülerden öz nitelik çıkarımı yapan CBIR konulu makaleler incelenecektir.
- Yazılımsal ihtiyaçlar:
 - python==3.x
 - pytorch, networkx
- Modelinin geliştirilmesi için ortam: Google Colab



Sistem	Performans Metrikleri			
	AC (%)	PR (%)	RC (%)	HL
[6]	57.12	75.16	71.90	5.24
[7]	61.09	77.54	74.70	4.67
Our	65+	80+	80+	4-

Deneylerde kullanılacak ölçüm metrikleri: (L_q , $L_{X_r^R}$ ve L_X sırasıyla X_q sorgu görüntüsü, X_r^R alınan görüntü ile eşleştirilen kategori etiketleri ve X arşivine iliştirilen kategori etiketleridir.

Metrik	Tanım
AC	$AC = \frac{1}{ X^R } \sum_{r=1}^{ X^R } L_q \cap L_{X_r^R} / L_q \cup L_{X_r^R} $
PR	$PR = \frac{1}{ X^R } \sum_{r=1}^{ X^R } L_q \cap L_{X_r^R} / L_{X_r^R} $
RC	$RC = \frac{1}{ X^R } \sum_{r=1}^{ X^R } L_q \cap L_{X_r^R} / L_q $
HL	$HL = \frac{1}{ X^R } \sum_{r=1}^{ X^R } L_q \Delta L_{X_r^R} / L_X $

Şekil 2: [7]

- Toplamda 4 tane olmak üzere, farklı performans ölçüm metriklerinde (Accuracy, Precision, Recall, Hamming Loss) hedeflediğimiz skorlar, literatürdeki farklı çalışmaların skorları ile karşılaştırmalı olarak gösterilmiştir.



- [1] Monali Metkar, Snehal Kamalapur, Spectral Imaging, *International Journal of Modern Electronics and Communication Engineering (IJMECE)* Volume No.-7, Issue No.-1, January, 2019
- [2] https://en.wikipedia.org/wiki/Hyperspectral_imaging
- [3] Maria Tzelepi, Anastasios Tefas, Deep convolutional learning for Content Based Image Retrieval, *Neurocomputing* Volume 275, 31 January 2018.
- [4] https://en.wikipedia.org/wiki/Content-based_image_retrieval
- [5] M. Graña and M. A. Veganzones, An endmember-based distance for content based hyperspectral image retrieval, *Pattern Recognition*, vol. 45, no. 9, pp. 3472 – 3489, 2012.
- [6] Migual A. Veganzones, Jose Orlando Maldonado, Manuel Grana, On Content-Based Image Retrieval Systems for Hyperspectral Remote Sensing, *Computational Intelligence for Remote Sensing* pp. 125-144. 2008.
- [7] Omruuzun, F., Demir, B., Bruzzzone, L., & Cetin, Y. Y. (2016). Content based hyperspectral image retrieval using bag of endmembers image descriptors. *2016 8th Workshop on Hyperspectral Image and Signal Processing: Evolution in Remote Sensing (WHISPERS)*.
- [8] Antonio J. Plaza, Content-Based Hyperspectral Image Retrieval Using Spectral Unmixing, *Image and Signal Processing for Remote Sensing XVII*, 2011.
- [9] WAN, Ji; WANG, Dayong; HOI, Steven C. H.; WU, Pengcheng; ZHU, Jianke; ZHANG, Yongdong; and LI, Jintao. Deep learning for content-based image retrieval: A comprehensive study. (2014). *MM '14: Proceedings of the 22nd ACM International Conference on Multimedia: November 3-7, 2014, Orlando*. 157-166. Research Collection School Of Information Systems.

