



**T.C.
GEBZE TEKNİK ÜNİVERSİTESİ**

Bilgisayar Mühendisliği Bölümü

**HİPERSPEKTRAL
GÖRÜNTÜLERDE İÇERİK
TABANLI GÖRÜNTÜ GERİ
ERİŞİMİ**

Ahmed Semih ÖZMEKİK

**Danışman
Prof. Dr. Erchan Aptoula**

**Ocak, 2021
Gebze, KOCAELİ**

Bu çalışma/200.. tarihinde aşağıdaki jüri tarafından Bilgisayar Mühendisliği Bölümü'nde Lisans Bitirme Projesi olarak kabul edilmiştir.

Bitirme Projesi Jürisi

Danışman Adı		
Üniversite		
Fakülte		

Jüri Adı		
Üniversite		
Fakülte		

Jüri Adı		
Üniversite		
Fakülte		

ÖNSÖZ

Bu kılavuzun ilk taslaklarının hazırlanmasında emeği geçenlere, kılavuzun son halini almasında yol gösterici olan Sayın Prof. Dr. Erchan APTOULA hocama ve bu çalışmayı destekleyen Gebze Teknik Üniversitesi'ne içten teşekkürlerimi sunarım.

Ayrıca eğitimim süresince bana her konuda tam destek veren aileme ve bana hayatlarıyla örnek olan tüm hocalarıma saygı ve sevgilerimi sunarım.

Ocak, 2020

Ahmed Semih ÖZMEKİK

İÇİNDEKİLER

ÖNSÖZ.....	iii
İÇİNDEKİLER.....	iv
ŞEKİL LİSTESİ.....	v
TABLO LİSTESİ.....	vi
KISALTMA LİSTESİ.....	vii
ÖZET.....	vii
SUMMARY.....	ix
1. GİRİŞ.....	1
1.1. PROJENİN TANIMI.....	1
1.2. HİPERSPEKTRAL GÖRÜNTÜLEME.....	2
1.3. GÖRÜNTÜ TABANLI İÇERİK ALIMI.....	2
1.4. PROBLEMİN ZORLUĞU.....	3
1.5. VERİ KÜMESİ: ANKARAHSIARCHIVE.....	4
1.6. PROJENİN TASARIMI.....	6
2. LİTERATÜR TARAMASI.....	6
1.1. UÇ ÜYE UZAKLIK.....	6
1.1. SPEKTRAL KARIŞTIRMA.....	7
1.1. UÇ ÜYE ÇANTASI.....	8
3. YAKLAŞIM.....	9
1.1. 2B-CNN.....	10
1.1. 3B-CNN.....	11
1.1. HYRIDSN.....	12
1.1. GENEL SONUÇLAR.....	13
6. VARGI.....	14
KAYNAKLAR.....	15

ŞEKİL LİSTESİ

ŞEKİL 1.1 Hiperspektral Görüntü Geri Erişimi	1
ŞEKİL 1.2 Hiperspektral Görüntü İmzaları.....	2
ŞEKİL 1.3 Görüntü Tabanlı İçerik Alımı Akış Diyagramı	3
ŞEKİL 1.4 Veri Kümesi Etiket Örnekleri	5
ŞEKİL 1.5 Proje Tasarım Planı.....	6
ŞEKİL 2.1 Uç Üye Tabanlı Uzaklık Çalışma Akış Diyagramı.....	6
ŞEKİL 2.2 Spektral Karıştırma	7
ŞEKİL 2.3 Uç Üye Çantası Çalışma Akış Diyagramı	8
ŞEKİL 3.1 Skor Ölçüm Metrik Tanımları	9
ŞEKİL 3.2 2B-CNN Mimarisi	11
ŞEKİL 3.3 3B-CNN Mimarisi	12
ŞEKİL 3.4 HybridSN Mimarisi	13

TABLO LİSTESİ

TABLO 1.1	Veri Kümesi Çoklu Etiket Dağılımları.....	4
TABLO 1.2	Veri Kümesi Ayrık Etiket Dağılımları.....	5
TABLO 2.1	Referans Çalışma Başarım Sonuçları.....	8
TABLO 3.1	2B-CNN Mimarisi.....	10
TABLO 3.2	2B-CNN Başarım Sonuçları.....	11
TABLO 3.3	2B-CNN Mimarisi.....	11
TABLO 3.4	3B-CNN Başarım Sonuçları.....	12
TABLO 3.5	HybridSN Başarım Sonuçları.....	13
TABLO 3.6	Genel Karşılaştırmalı Başarım Sonuçları.....	13

KISALTMA LİSTESİ

PCA	: Temel Bileşen Analizi (Principal Component Analysis)
2B	: 2 Boyutlu
3B	: 3 Boyutlu
CNN	: Evrişimli Sinir Ağı (Convolutional Neural Network)
AC	: Doğruluk (Accuracy)
PR	: Kesinlik (Precision)
RC	: Duyarlılık (Recall)
HL	: Hamming Loss
RELU	: Düzeltilmiş Doğrusal Birim (Rectified Linear Unit)

ÖZET

Gelişen uzaktan algılama ve hipespektral görüntüleme sistemleri ile birlikte birçok görüntü arşivleri toplanmış, büyüyen bu hiperspektral görüntü uzayını bünyesinde barındıran pek çok sistem geliştirilmiştir. Hızla büyüyen hiperspektral görüntü arşivleri üzerinde hızlı görüntü arama ve erişimleri sağlamak, büyük bir ihtiyaca dönüşmüştür.

Projede, bu ihtiyaçtan hareketle, hiperspektral görüntü kümesi üzerinde içerik tabanlı görüntü erişimi gerçekleştirme amaçlanmıştır. Literatürdeki mevcut yöntemler incelenmiş ve hiperspektral görüntülerin geniş bant bilgisine sahip olması göz önünde bulundurularak derin öğrenme yöntemleriyle deneyler gerçekleştirilmiştir.

Çalışmada, 2B ve 3B CNN mimarisine sahip derin ağlar hiperspektral görüntülerdeki bant genişliğini değerlendirmek üzere geliştirilmiş, literatürde hiperspektral verilere yönelik geliştirilen bazı derin ağ mimarileri gerçekleştirilmiş ve AnkaraHSI veri kümesinde üzerinde skorlar elde edilmiştir. Skorlar, referans çalışmalar ile karşılaştırmalı olarak sunulmuştur.

Çalışma sonucunda referans çalışmadaki başarımların skorları, geliştirilen modeller ile beklenildiği üzere artırılmış ve deney sonuçları kaydedilmiştir.

SUMMARY

Along with the developing remote sensing and hyperspectral imaging systems, many image archives have been collected, and many systems that contain this growing hyperspectral image space have been developed. Providing fast image search and access on rapidly growing hyperspectral image archives has become a great need.

In the project, based on this need, aim is to realize content based image retrieval on the hyperspectral image collection. Existing methods in the literature were examined and experiments were carried out with deep learning methods, considering that hyperspectral images have rich spectral information.

In the study, deep networks with 2D and 3D CNN architectures were developed to evaluate the bands in hyperspectral images, some deep network architectures developed for hyperspectral data in the literature were implemented and scores were obtained on the AnkaraHSI dataset. Scores are presented in comparison with reference studies.


As a result of the study, the performance scores in the reference study were increased as expected with the developed models and the experimental results were recorded.

1. GİRİŞ

1.1. PROJENİN TANIMI

Hiperspektral görüntüleme, insan gözünün 3 bantta algılayabildiği görünür ışıktan farklı olarak tayfı bir çok banda ayırdığından materyallerin tespitini ve ayrımını mümkün kılan yoğun spektral bilgiye sahiptir. [1, 2]

Proje, görüntüyü birçok banda ayıran bu teknik sayesinde elde edilmiş hiperspektral görüntü uzayında, bir görüntü ile arama yaparak koleksiyondan sorgu görüntüye en çok benzeyen görüntülerin alımını gerçekleştiren program yapmaktır.



ŞEKİL 1.1 Hiperspektral Görüntü Geri Erişimi [3]

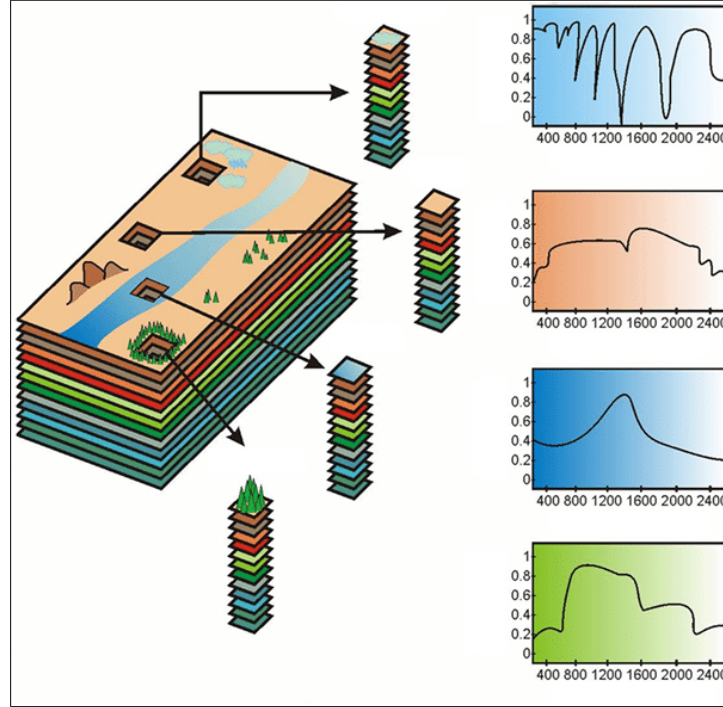
İçerik Tabanlı Görüntü Alımı, bilgisayarla görü tekniklerinin görüntü alımı problemlerine (büyük veri tabanlarında dijital görüntülerin aranması problemlerine) uygulanmasıdır. İçerik Tabanlı arama; sorgunun anahtar sözcük ve etiket gibi meta verilerinden ziyade görselin içeriğinin analiz edilerek yapıldığı anlamına gelir [4]. Projedeki, hiperspektral görüntülerin pek çok farklı ve zengin bant genişliğinden faydalanarak, derin öğrenme yöntemleriyle başarılı bir görüntü alımı gerçekleştirmektir.

Hiperspektral görüntüler uzayındaki görüntü alımının uygulama alanları kapsamlıdır. Afet hassasiyeti, çevre analizi ve güvenlik için birçok jeobilim araçlarına ve bu uygulamalardaki hiperspektral görüntü veri tabanlarının artmasıyla ihtiyaç duyulan görüntü alımı araçlarına ihtiyaç duyulmaktadır. [5]

Proje, bu ihtiyaçtan hareketle, literatürdeki mevcut yöntemlerin incelenmesiyle, geniş spektral bilgiyi değerlendirerek bir görüntü alımı gerçekleştirmeyi hedeflemektedir.

1.2. HİPERSPEKTRAL GÖRÜNTÜLEME

İnsan gözünün mavi, yeşil ve kırmızıda sadece üç renk alıcısı varken, hiperspektral görüntüleme, sadece görünürde değil, aynı zamanda yakın kızılötesinde de ince dalga boyu çözünürlüğü ile sahnenin her pikseli için ışığın sürekli spektrumunu ölçen bir görüntüleme tekniğidir. Toplanan veriler, iki boyutun sahnenin uzamsal kapsamını ve üçüncüsünün spektral içeriğini temsil ettiği bir hiperspektral küp oluşturur. Şekil’de belirli bir yapılan hiperspektral görüntülemeden elde edilen farklı hiperküpler ve onların farklı spektral imzaları temsilen gösterilmiştir.



ŞEKİL 1.2 Hiperspektral Görüntü İmzaları [6]

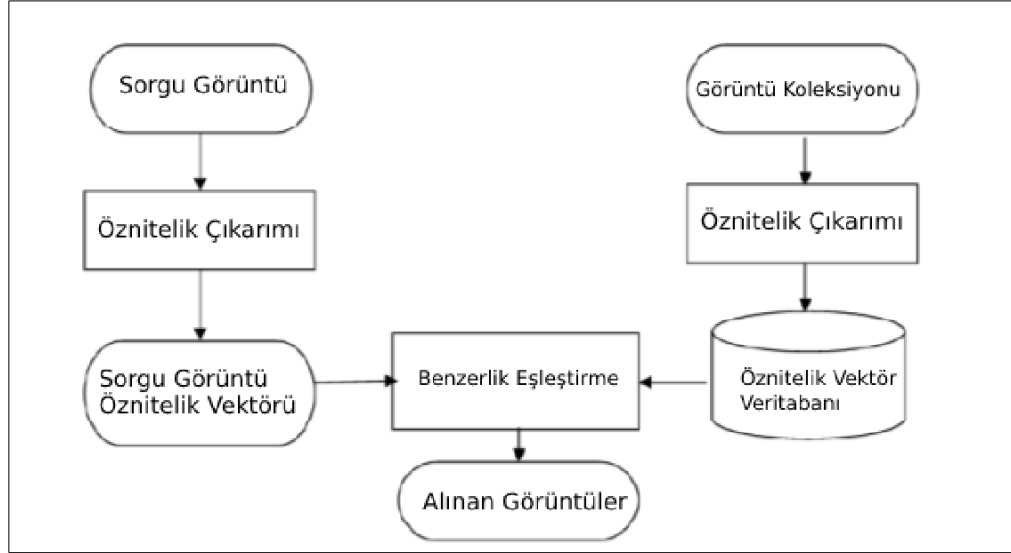
Hiperspektral ve multispektral görüntüler arasındaki ayrım bazen rastgele bant sayısına veya ölçüm türüne dayanır. Hiperspektral görüntüleme (HSI), sürekli ve bitişik dalga boyu aralıklarını (ör. 1 nm’lik adımlarla 400 - 1100 nm) kullanırken, çok bantlı görüntüleme (MSI), seçilen konumlarda hedeflenen dalga boylarının bir alt kümesini kullanır (örneğin, 20 nm’lik adımlarla 400 - 1100 nm). [7]

Bu projede hedef girdiler hiperspektral görüntülerdir.

1.3. GÖRÜNTÜ TABANLI İÇERİK ALIMI

İnternetin gelişmesi ve dijital kameralar, görüntü tarayıcılar gibi görüntü yakalama cihazlarının mevcudiyetiyle birlikte, dijital görüntü toplama hızı artmaktadır. Uzaktan algılama, suç önleme, yayıncılık, ilaç, mimari vb. birçok çeşitli alanlarda kullanıcılar için verimli görüntü arama, tarama ve erişim

araçları gereklidir. Bu amaçla, birçok genel amaçlı görüntü erişim sistemi geliştirilmiştir. İki başlık altında incelenebilir: Metin tabanlı ve içerik tabanlı. Metin tabanlı yaklaşım 1970'lere uzanmakta ve bu tür sistemlerde görüntüler, manuel olarak etiketlenen metadata verileri ile temsil edilmekte ve daha sonra bir veritabanı yönetim sistemi tarafından bu metin tabanlı etiketler üzerinden alımı gerçekleştirilmektedir. Bu yaklaşımın iki dezavantajı vardır. Birincisi, manuel açıklama için önemli düzeyde insan emeğinin gerekli olduğudur. İkincisi, insan algısının öznelliğinden kaynaklanan açıklama yanlışlığıdır [8,9]. Metin tabanlı erişim sistemindeki bu dezavantajların üstesinden gelmek için, içerik tabanlı görüntü alımı (CBIR) 1980'lerin başında tanıtılmıştır. CBIR'de görüntüler; renk, doku, şekiller gibi görsel içeriklerine göre, yani içeriğine göre, herhangi bir manuel etiketleme olmadan indekslenmektedir. [10] Genel bir içerik tabanlı görüntü alımı tasarım şeması şekilde gibidir.



ŞEKİL 1.3 Görüntü Tabanlı İçerik Alımı Akış Diyagramı

Bu projedeki amaç, görüntü tabanlı içerik alımını hiperspektral görüntüler uzayında gerçekleştirmektedir.

1.4. PROBLEMİN ZORLUĞU

Literatür taramasının aktarıldığı bölümde daha çok bahsedilmek üzere, tasarımdaki esas modül öznitelik çıkarımının gerçekleştirildiği modüldür. Bu modülde görüntülerin öznitelik çıkarımı, yani bir hiperspektral görüntüden o görüntüyü temsil eden en başarılı vektörün çıkarımı gerçekleştirilecektir. Bu öznitelik vektöründe, o görüntünün temsil edilebilirliği önem arz etmektedir.

Projedeki görüntü uzayı, hiperspektral görüntülerden oluştuğundan problemin girdisi uzamsal ve spektral pek çok veriden derin öznitelik çıkarımını gerektirmektedir.

1.5. VERİ KÜMESİ: AnkaraHSIArchive

Veri kümesi, araştırma amacıyla yayınlanan küçük bir hiperspektral görüntü arşividir. Arşiv, EO-1 Hyperion sensörü tarafından elde edilen hiperspektral bir görüntünün Ankara çevresi üzerinde parçalanmasıyla elde edilen 216 hiperspektral görüntü karesinden oluşmaktadır. Her bir görüntü karosu, birden fazla arazi örtüsü sınıf etiketi (bkz. Tablo 1) ve arazi kullanımı kategori etiketi (bkz. Tablo 2) ile açıklanmıştır. Görüntüleme 30 metre yükseklikten, Ankara çevresinde, 2015 Ağustosunda yapılmıştır.

TABLO 1.1 Veri Kümesi Çoklu Etiket Dağılımları

Arazi Örtüsü Sınıfı (Çoklu)	Görüntü Sayısı
Çim Kaplı Toprak	215
Çıplak Toprak	216
Kurak Toprak	10
Kayalık	31
Ağaçlık	174
Sazlık	5
İşlenmiş (Tip-A)	47
İşlenmiş (Tip-B)	38
İşlenmiş (Tip-C)	2
İşlenmiş (Tip-D)	55
İşlenmiş (Tip-E)	4
Kırmızı Çatı	131
Metal Çatı	130
Beyaz Çatı	122
Yeşil Çatı	41
Mavi Çatı	25
Sarı Çatı	13
Membran Çatı	57
Beton Çatı	55
Beyaz Çadır	6
Kaldırımsız Yol	106
Asfalt Yol	183
Karayol	12
Çim (Tip-A)	215
Çim (Tip-B)	12

Çim (Tip-C)	25
Göl	11
Havuz	23
Bulut	6

TABLO 1.2 Veri Kümesi Ayırık Etiket Dağılımları

Arazi Kullanım Sınıfı (Ayrık)	Görüntü Sayısı
Kırsal Alan	43
Kentsel Alan	37
Ekili Arazi	126
Orman	10


Arşivde toplamda 216 görüntü ve her bir görüntüde 119 bant bulunmaktadır, her bantta 63x63 piksel bulunmaktadır. Her bir görüntü, birden çok arazi örtüsü sınıfı (29 sınıf) ve bir arazi kullanım sınıfı (4 ayrık sınıf) ile etiketlenmiş olarak bulunmaktadır. Şekilde bu etiketleme verilerinden, hem ayrık sınıf hem de birden çok etiket ile yapılmış etiketlemenin örnekleri görülmektedir.

1	Image	Category	Land-Use Category
2	001	1	1 Rural Area
3	002	1	2 Urban Area
4	003	1	3 Cultivated Land
5	004	1	4 Forest
6	005	1	
...			

1	Image	Grass Covered Soil	Bare Soil	Arid Soil	Rocky	Tree	Reeds	...
2	001	x	x			x		
3	002	x	x			x		
4	003	x	x			x		
5	004	x	x			x		
6	005	x	x			x		
7	006	x	x			x		
8	007	x	x			x		
9	008	x	x			x		
10	009	x	x			x		
11	010	x	x			x		
...								

ŞEKİL 1.4 Veri Kümesi Etiket Örnekleri

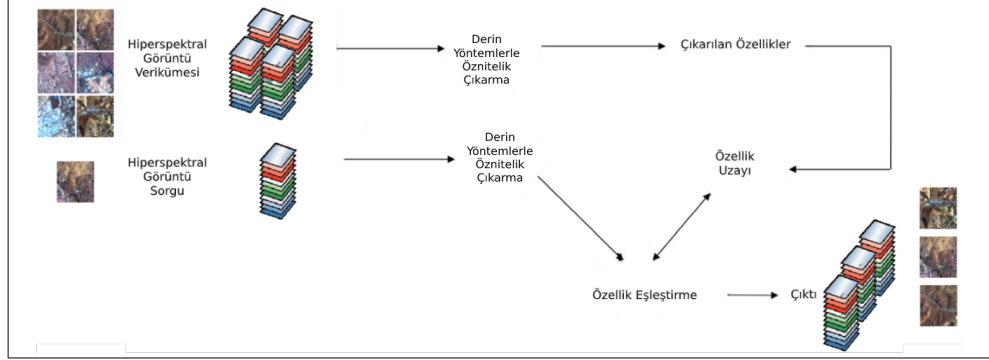
Görüntü kümesinden bazı örnekler, ayrık sınıf etiketleriyle birlikte aşağıdaki şekilde görülmektedir.



ŞEKİL 1.5 Veri Kümesi Görüntü Örnekleri

1.6. PROJENİN TASARIMI

Tanıtılan verikümesi, hiperspektral görüntüler ve görüntü alımı sistemlerinin sonunda projenin çalışma akışı şekildeki gibi temsil edilebilir.

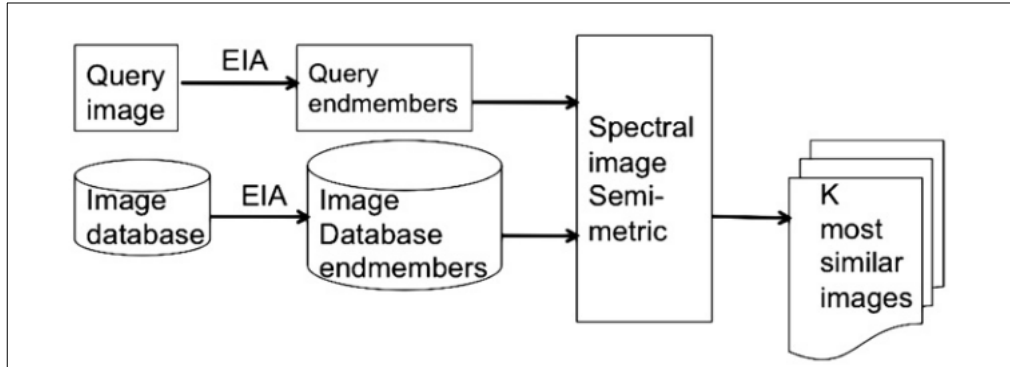


ŞEKİL 1.5 Proje Tasarım Planı

2. LİTERATÜR TARAMASI

Probleme yönelik literatürde geliştirilen yaklaşımlar genel itibariyle, derin (deep) ve sığ (shallow) yaklaşımlar olmak üzere 2 farklı başlığa ayrılmaktadır. Derin yöntemler, derin öğrenme kullanılarak geliştirilen modellerin mimarisindeki belirli katmanlarının öz nitelik vektörü olarak kullanılmasıyla, sığ yöntemler ise PCA, LDA vb. öz nitelik çıkarımı yapan modeller ile yapılmaktadır.

2.1. UÇ ÜYE TABANLI UZAKLIK (ENDMEMBER-BASED DISTANCE) [5]



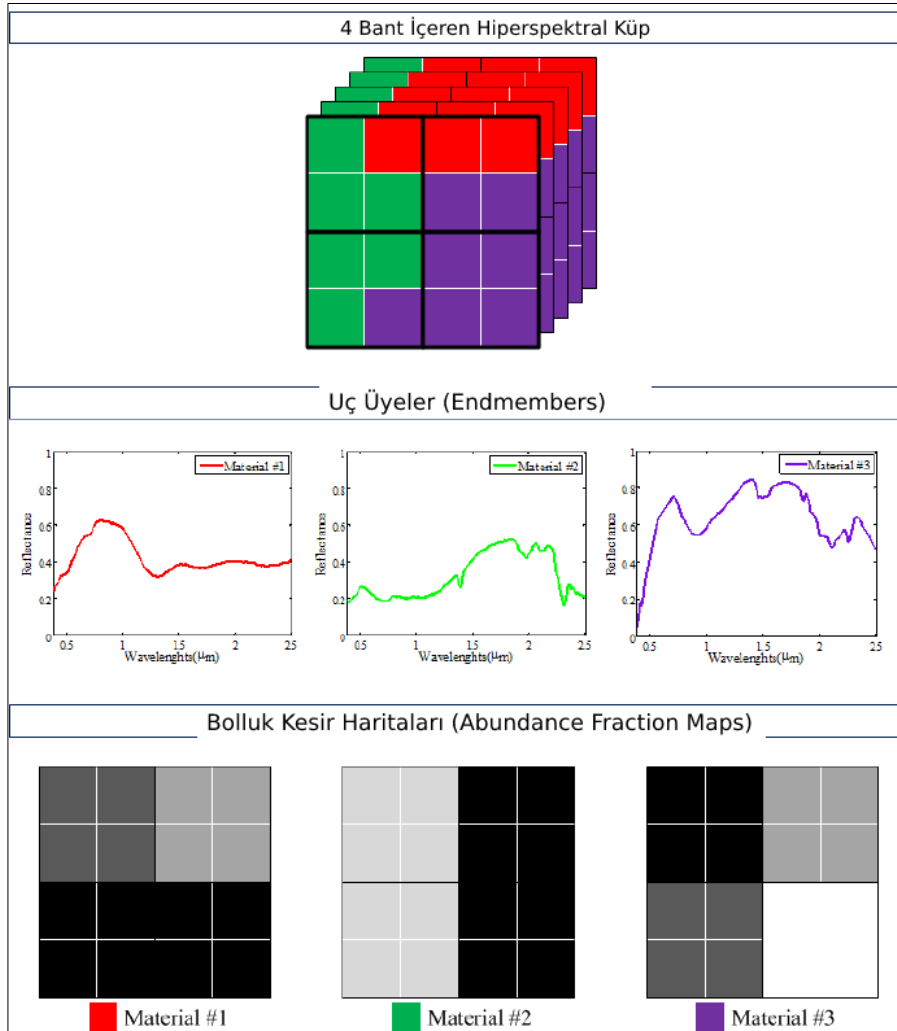
ŞEKİL 2.1 Uç Üye Tabanlı Uzaklık Çalışma Akış Diyagramı [5]

Bu çalışmadaki, görüntü öznitelikleri, görüntü verilerinden son üye indüksiyon algoritmaları (EIA'lar) ile elde edilen son üye imzalarıdır (endmember signatures). Son üyeler, sahnedeki temel malzemelere karşılık gelmektedir. Piksel spektrumları, uç üye imzalarının bir kombinasyonuna ayrıştırılmaktadır.

Bu çalışmadaki katkılar ve özellikler, uç üye elde etmek için kullanılan EIA yöntemi ve görüntülerin uç üyelerinin arasındaki uzaklığı bulan bulan bir fonksiyon tanımlamasıdır. Eksikliği ise sistemin, verilerin gerçek referans değerlerine ve görüntü boyutuna duyarlı olmasıdır.

2.1.2. SPEKRAL KARIŞTIRMA (SPECTRAL UNMIXING) [11]

Literatürde birbirinden farklı pek çok Spektral Karıştırma yöntemi bulunmaktadır ve çalışma akışındaki girdi ve çıktılar şekildeki gibidir.

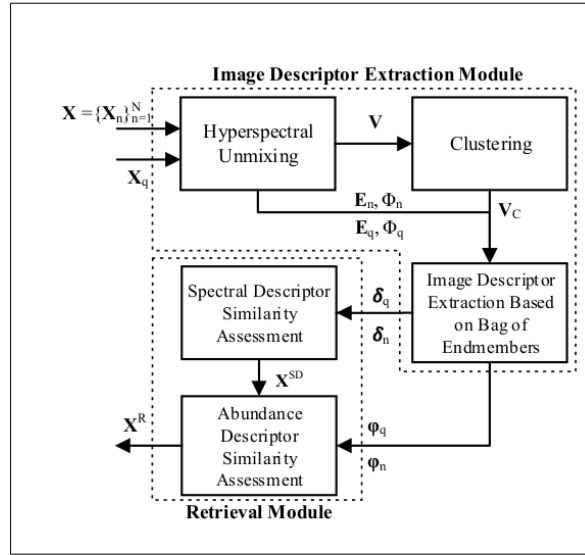


ŞEKİL 2.2 Spektral Karıştırma [12]

Bu çalışmada, Uç Üye çıkarımı için, önce PCA uygulanmış, sonra girdiden rastgeler değerler ile uç üyeler iklendirilmiş ve hacim hesaplaması yapılmıştır. Ardından Değiştirme (Replacement) olarak tanımlanan bir algoritmayla uç üyeler son değerlerini kazanmışlardır. Kısacası yapılan çalışma, bir spektral karıştırma gerçekleştirilmesini belirtir.

2.1.3. UÇ ÜYE ÇANTASI (BAG OF END-MEMBERS) [13]

Bu çalışma, projede referans aldığımız temel çalışmadır.



ŞEKİL 2.3 Uç Üye Çantası Çalışma Akış Diyagramı [13]

Çalışmada, 2 farklı modül bulunmaktadır: Birincisi, görüntü tanımlayıcıların çıkarımının yapıldığı, ardından bu tanımlayıcılar arasındaki karşılaştırmaların yapıldığı modül. Çalışmada aktarılan skor karşılaştırması tablosu aşağıdaki gibidir.

TABLO 2.1 Referans Çalışma Başarım Sonuçları

Sistem	Performans Metrikleri			
	AC (%)	PR (%)	RC (%)	HL
[5]	57.12	75.16	71.90	5.24
[13]	61.09	77.54	74.70	4.67

Çalışmadaki veri kümesi projede kullanılmıştır, ve elde edilen sonuçlar karşılaştırmalı olarak gösterilecektir.

3. YAKLAŞIM

Çalışmada, genel tasarım aynı kalacak şekilde, yalnızca derin ağı model mimarisinin değiştirilmesi suretiyle elde edilecek skorlar, daha sonra bu skorlardan hareketle mimari üzerindeki ince ayarlar yapılarak bazı derin öğrenme deneyleri gerçekleştirilmiştir.

Her bir model, 4 adet sınıf üzerinde sınıflandırma yapan derin ağı modeli olarak geliştirilmiştir. Ardından elde edilen mimariyle içerik tabanlı erişim gerçekleştirilmiştir. İçerik tabanlı erişimde benzerlik ölçütü referans çalışma temel alınarak belirlenmiştir. Bir sorgu görüntü sisteme verildiğinde gerçekleşen alımın başarı değeri, alınan 5 sonuç görüntünün doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve Hamming Loss değerlerinin ortalaması alınarak hesaplanmıştır. Bu skor değerlerinin tanımları şu şekildedir:

Deneylerde kullanılacak ölçüm metrikleri: (L_q , $L_{X_r^R}$ ve L_X sırasıyla X_q sorgu görüntüsü, X_r^R alınan görüntü ile eşleştirilen kategori etiketleri ve X arşivine iliştilen kategori etiketleridir.

Metrik	Tanım
AC	$AC = \frac{1}{ X^R } \sum_{r=1}^{ X^R } L_q \cap L_{X_r^R} / L_q \cup L_{X_r^R} $
PR	$PR = \frac{1}{ X^R } \sum_{r=1}^{ X^R } L_q \cap L_{X_r^R} / L_{X_r^R} $
RC	$RC = \frac{1}{ X^R } \sum_{r=1}^{ X^R } L_q \cap L_{X_r^R} / L_q $
HL	$HL = \frac{1}{ X^R } \sum_{r=1}^{ X^R } L_q \Delta L_{X_r^R} / L_X $

ŞEKİL 3.1 Skor Ölçüm Metrik Tanımları

Veri kümesinde, 4 farklı kategori sınıfının yanı sıra her görüntü (sınıflar ayrık değildir ve bir örnek birden fazla sınıfla etiklenebilir) toplamda 29 farklı sınıf ile etiketlenmiş bulunmaktadır. Benzerlik ölçütümüz (tabloda görülebileceği üzere);

Doğruluk (AC), sorgu ve sonuç görüntünün kategori etiketleri kümelerinin kesişim kümesi eleman sayısının, birleşim kümesi eleman sayısına oranıdır. Sorgu ve alınan sonucunun ortak kategori etiketleri ne kadar fazlaysa doğruluk anlamında birbirlerine benzemektedirler.

Kesinlik (PC), sorgu ve sonuç görüntünün kategori etiketleri kümelerinin kesişiminin eleman sayısının, sonuç görüntünün kategori kümesinin eleman sayısına oranıdır.

Duyarlılık (RC), sorgu ve sonuç görüntünün kategori etiketleri kümelerinin kesişiminin eleman sayısının, sorgu görüntünün kategori kümesinin eleman sayısına oranıdır.

Hamming Loss (HL), sorgu ve sonuç görüntünün kategori etiketleri kümelerinin kesişmeyen eleman sayısının, ayrık sınıf sayısına (4) oranıdır.

Tanımlanan bu değerler, içerik tabanlı (öznitelik vektörlerinin öklid uzaklığı ile) erişim gerçekleştirilerek bulunan sorgu görüntüye en yakın 5 görüntünün sonuçlarının ortalaması alınarak hesaplanmıştır.

Genel sonuçlar için ise, veri kümesindeki 216 görüntünün her biri için bir sorgu gerçekleştirilmiş ve elde edilen sonuçların ortalaması alınarak hesaplanmıştır.

Bir derin ağı modeli için yapılan görüntü geri alım sonuçları, çapraz geçerlilik (k-fold cross validation) elde edilen 5 farklı küme grubu (eğitim, test ve geçerleme kümeleri) ile edilen modelin geri alım sonuçlarının ortalaması alınarak hesaplanmıştır.

Tüm modeller için, 216 adet görüntüyü barındıran veri kümesi derin öğrenmede, %80 eğitim kümesi, %10 doğrulama kümesi, %10 test kümesi olarak ayrılarak kullanılmıştır.


3.1. 2B-CNN

İlk aşamada, 2B-CNN adıyla bahsedilecek olan, şekilde derin ağ mimarisinde deneyler yapılmıştır.

TABLO 3.1 2B-CNN Mimarisi

Katman Adı	Katman Boyutu
Girdi Katmanı	(63, 63, 119)
Evrişimli 2B Katman 1	(61, 61, 32), (3, 3)
Örnekleme 2B Katman 1	(30, 30, 32), (2, 2)
Evrişimli 2B Katman 2	(28, 28, 64), (3, 3)
Örnekleme 2B Katman 2	(14, 14, 64), (2, 2)
Evrişimli 2B Katman 3	(12, 12, 64), (3, 3)
Düzleştirme Katman 1	(9216)
Tam Bağlı Katman RELU 1	(64)
Tam Bağlı Katman RELU 2	(4)

Öznitelik vektörü olarak, Tam Bağlı Katman 1, alınmıştır. Şekilde mimari görsel olarak gösterilmiştir.



ŞEKİL 3.2 2B-CNN Mimarisi

Sınıflandırmanın başarımlı oranı, test kümesinde 0.7090 olarak kaydededilmiştir. Görüntü geri erişim sisteminde kullanılan farklı uzaklık metriklerindeki başarı oranlı tabloda verilmiştir.

TABLO 3.2 2B-CNN Başarımlı Sonuçları

Sistem	Performans Metrikleri			
	AC (%)	PR (%)	RC (%)	HL
[13]	61.09	77.54	74.70	4.67
L0	56.45	71.76	74.05	5.17
L1	62.06	77.10	76.89	4.42
L2	62.12	77.11	76.92	4.41
LINF	61.95	77.06	76.72	4.43

3.2. 3B-CNN


3B-CNN, hiperspektral açıyı, üçüncü boyutu daha iyi değerlendirebilmek üzere geliştirilmiştir. Mimarisi şekildeki gibidir.

TABLO 3.3 3B-CNN Mimarisi

Katman Adı	Katman Boyutu
Evrişimli 2B Katman 1	(61, 61, 117, 32)
Örnekleme 2B Katman 1	(30, 30, 58, 32)
Evrişimli 2B Katman 2	(28, 28, 56, 64)
Örnekleme 2B Katman 2	(14, 14, 28, 64)
Evrişimli 2B Katman 3	(12, 12, 26, 64)
Düzleştirme Katman 1	(239616)
Tam Bağlı Katman RELU 1	(128)

Tam Bağlı Katman RELU 2	(64)
Tam Bağlı Katman RELU 3	(4)

Öznitelik vektörü olarak, Tam Bağlı Katman 2, alınmıştır. Şekilde mimari görsel olarak gösterilmiştir.



ŞEKİL 3.3 3B-CNN Mimarisi

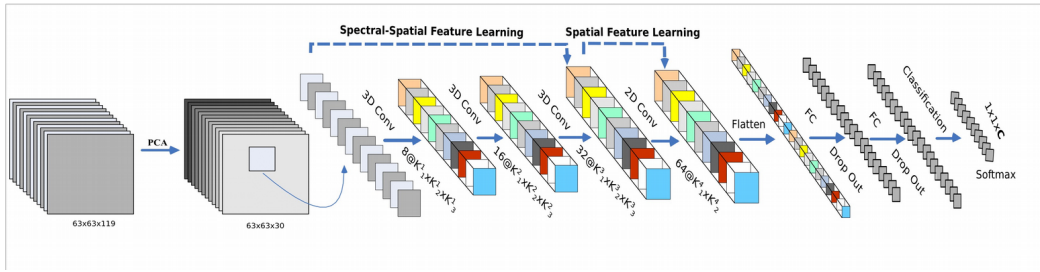
Sınıflandırmanın başarımlı oranı, test kümesinde 0.7273 olarak kaydedilmiştir. Görüntü geri erişim sisteminde kullanılan farklı uzaklık metriklerindeki başarı oranları tabloda verilmiştir.

TABLO 3.4 3B-CNN Başarımlı Sonuçları

Sistem	Performans Metrikleri			
	AC (%)	PR (%)	RC (%)	HL
[13]	61.09	77.54	74.70	4.67
L0	57.60	71.74	75.57	4.95
L1	61.77	77.46	76.28	4.45
L2	62.14	77.59	76.56	4.42
LINF	62.49	77.65	76.85	4.38

3.3. HybridSN [14]

Hem spektral hem uzamsal açıyı değerlendiren hibrid bir çalışma, literatürde tespit edilip hem temel bileşen analizi (PCA) uygulanarak hem de uygulanmadan test edilerek denenmiştir. Mimarisi aşağıdaki şekilde gösterilmiştir.



ŞEKİL 3.4 HybridSN Mimarisi

Sınıflandırmanın başarımlar oranı, test kümesinde, temel bileşen analizi uygulanarak 119 katmandan 30 katmana indirilerek 0.5727, temel bileşen analizi olmadan ise 0.5563 olarak kaydedilmiştir. Geri alım skorları her ikisinde de, referans skorlarından daha kötü olduğu için, aralarından daha iyi sonuç veren olan temel bileşen analizli modelin skorları tabloda verilmiştir.

TABLO 3.5 HybridSN Başarım Sonuçları

Sistem	Performans Metrikleri			
	AC (%)	PR (%)	RC (%)	HL
[13]	61.09	77.54	74.70	4.67
L0	53.83	68.81	73.14	5.73
L1	55.57	72.37	72.00	5.31
L2	55.95	72.69	72.03	5.26
LINF	55.63	72.32	72.26	5.31

3.4. Genel Sonuçlar

Modellerin en iyi sonuçları karşılaştırıldığında, 3B-CNN modeli (RC değeri hariç diğer tüm metriklerde) en iyi skorları vermektedir.

TABLO 3.6 Genel Karşılaştırmalı Başarım Sonuçları

Sistem	Performans Metrikleri			
	AC (%)	PR (%)	RC (%)	HL
[13]	61.09	77.54	74.70	4.67
2B-CNN	62.12	77.11	76.92	4.41
3B-CNN	62.49	77.65	76.85	4.38
HybridSN (PCA)	55.95	72.69	72.03	5.26
HybridSN	53.83	66.93	73.68	6.18

4. VARGI

Projedeki deneyler neticesinde; 2 boyutlu CNN, sıg yöntemlerden daha başarılı sonuç vermiştir. Bunun yanında beklenildiğı gibi bant genişliğini daha iyi değerlendiren 3 boyutlu CNN modeliyle yapılan öznitelik çıkarımı daha başarılı sonuçlar vermiştir. Hem spektral hem uzamsal açıyı değerlendiren HybridSN modelinin eğitiminde incelenen eğitim, geçerleme ve test kümesindeki sınıflandırma skorları değerlendirildiğinde, modelin –diğer mimarilere kıyasla daha karmaşık olmasının buna sebep olduğu düşünülerek– ezberleme (overfitting) yaptığı görülmektedir.

Veri kümesinin yalnızca 216 örnek görüntüyü barındırmaktadır ve elde edilen sonuçlar yalnızca bu veri kümesinde gösterilmiştir. Dolayısıyla sistemin gürbüzlüğünün daha iyi kanıtlanabilmesi için, benzer yapıya sahip, yani hem ayrık ve hemde birleşik etiketlemelerin yapıldığı başka bir veri kümesinde de denenmelidir.

Elde edilen sonuçlar hedeflenen skorun altında kalmıştır. Sistemde veri kümesindeki 26 sınıftan oluşan çoklu etiket (multilabel) bilgileri yalnızca geri erişim modülünün başarımlarını tespit etmekte kullanılmıştır; daha başarılı bir sistem için bu etiket bilgilerinin öznitelik çıkarım modülüne dahil edilmesi önerilmektedir.

Benzer şekilde, çoklu etiket bilgilerinin modelin, dolayısıyla öznitelik vektörünün görüntüyü temsil edebilirliğini arttırmak için, geri erişim sisteminin başarısını değerlendirerek kullanabilecek bir kayıp fonksiyonundan geri besleme yapılarak bir derin öğrenme modelinin geliştirilmesi önerilmektedir.

KAYNAKLAR

- [1] https://en.wikipedia.org/wiki/Hyperspectral_imaging
- [2] Maria Tzelepi, Anastasios Tefas, Deep convolutional learning for Content Based Image Retrieval, Neurocomputing Volume 275, 31 January 2018.
- [3] Monali Metkar, Snehal Kamalapur, Spectral Imaging, International Journal of Modern Electronics and Communication Engineering (IJMECE) Volume No.-7, Issue No.-1, January, 2019
- [4] https://en.wikipedia.org/wiki/Content-based_image_retrieval
- [5] M. Graña and M. A. Veganzones, An endmember-based distance for content based hyperspectral image retrieval, Pattern Recognition, vol. 45, no. 9, pp. 3472 – 3489, 2012.
- [6] Plaza, Javier & Plaza, Antonio & Barra, Cristina. (2009). Multi-Channel Morphological Profiles for Classification of Hyperspectral Images Using Support Vector Machines. Sensors (Basel, Switzerland). 9. 196-218.
- [7] CM Veys; et al. (2017). "An Ultra-Low-Cost Active Multispectral Crop Diagnostics Device" . IEEE Sensors Journal. 113: 1005–1007.
- [8] J. Eakins, M. Graham, Content-based image retrieval, Technical Report, University of Northumbria at Newcastle, 1999.
- [9] I.K. Sethi, I.L. Coman, Mining association rules between low-level image features and high-level concepts, Proceedings of the SPIE Data Mining and Knowledge Discovery, vol. III, 2001, pp. 279–290.
- [10] Ying Liu, Dengsheng Zhang, Guojun Lu, Wei-Ying Ma, A survey of content-based image retrieval with high-level semantics, Pattern Recognition, Volume 40, Issue 1, 2007, Pages 262-282, ISSN 0031-3203.
- [11] Antonio J. Plaza, Content-Based Hyperspectral Image Retrieval Using Spectral Unmixing, Image and Signal Processing for Remote Sensing XVII, 2011.
- [12] Rajabi, Roozbeh & Ghassemian, Hassan. (2014). Sparsity Constrained Graph Regularized NMF for Spectral Unmixing of Hyperspectral Data. Journal of the Indian Society of Remote Sensing. 43.
- [13] Omruuzun, F., Demir, B., Bruzzone, L., & Cetin, Y. Y. (2016). Content based hyperspectral image retrieval using bag of endmembers image descriptors. 2016 8th Workshop on Hyperspectral Image and Signal Processing: Evolution in Remote Sensing (WHISPERS).
- [14] S. K. Roy, G. Krishna, S. R. Dubey and B. B. Chaudhuri, "HybridSN: Exploring 3-D–2-D CNN Feature Hierarchy for Hyperspectral Image Classification," in IEEE Geoscience and Remote Sensing Letters, vol. 17, no. 2, pp. 277-281, Feb. 2020.